

RELATÓRIO TÉCNICO — PROJETO P2

Sobrevivência no Titanic — Classificação Binária com Machine Learning

Curso	Bacharelado em Inteligência Artificial — UNIMAR
Grupo	12
Integrantes	Felipe Traskini Rocha (2028148)
	Samuel Alves Vieira (2041169)
	Ivan Luís Gerônimo Del Roio (2031330)
Dataset	Kaggle — Titanic: Machine Learning from Disaster
Versão	P2 — Final Junho/2026

Melhorias implementadas na P2 em relação à P1:

- ✓ Adição de Matriz de Correlação e análise de Outliers na EDA (ausentes na P1)
- ✓ Matriz de Confusão e Curva ROC geradas para os 3 modelos (P1 gerava apenas para Random Forest)
- ✓ Conjunto de teste estritamente isolado, usado somente na avaliação final
- ✓ Alinhamento total entre outputs do notebook e valores deste relatório

1. Introdução e Objetivo

Este projeto analisa o naufrágio do Titanic (1912) como um problema de classificação binária supervisionada, com o objetivo de prever a probabilidade de sobrevivência de cada passageiro. A variável-alvo é Survived (0 = não sobreviveu, 1 = sobreviveu), e as variáveis preditoras incluem atributos demográficos, socioeconômicos e familiares.

O dataset utilizado é o arquivo Titanic-Dataset.csv, proveniente da competição oficial Kaggle Titanic: Machine Learning from Disaster, com 891 registros rotulados. Nenhum arquivo externo adicional é necessário para executar o notebook.

Etapas	Descrição	Status P2
EDA	Taxas de sobrevivência, correlações, outliers, missing	Expandida
Feature Eng.	Title, FamilySize, IsAlone, HasCabin	Mantida
Pré-processamento	Imputação, encoding, winsorização, StandardScaler	Anti-leakage
Validação	Stratified K-Fold (k=5) sobre treino+validação	Corrigida
Avaliação	Confusão + ROC para 3 modelos + teste isolado	Corrigida
Deploy	Gradient Boosting salvo (.pkl) + App Streamlit	Novo na P2

2. Análise Exploratória de Dados (EDA)

2.1 Taxa de Sobrevivência por Grupos

A análise exploratória revelou padrões estatisticamente significativos que confirmam hipóteses históricas sobre a evacuação do Titanic:

Variável	Categoria	Taxa de Sobrevivência	N
----------	-----------	-----------------------	---

Geral	—	38,38%	891
Sex	Feminino	74,20%	314
Sex	Masculino	18,89%	577
Pclass	1ª Classe	62,96%	216
Pclass	2ª Classe	47,28%	184
Pclass	3ª Classe	24,24%	491
Faixa Etária	Criança (0–12)	57,89%	76

2.2 Valores Ausentes

Feature	Missing (n)	% Missing	Estratégia
Age	177	19,87%	Mediana por Título (calculada no treino)
Cabin	687	77,10%	Convertida em HasCabin (variável binária 0/1)
Embarked	2	0,22%	Moda do conjunto de treino

2.3 Detecção e Tratamento de Outliers (IQR)

Outliers identificados pelo método IQR (Interquartile Range). Valores além de $1,5 \times \text{IQR}$ do Q1 ou Q3 são considerados atípicos:

Feature	Q1	Q3	Lim. Superior	Outliers	Ação
Fare	£7,91	£31,00	£65,63	116 (13,0%)	Winsorização P99 do treino
Age	20,12	38,00	64,82	11 (1,2%)	Mantidos (valores plausíveis)
SibSp	0	1	3	46 (5,2%)	Mantidos (informativos)
Parch	0	0	0	213 (23,9%)	Mantidos (informativos)

2.4 Matriz de Correlação de Pearson

A correlação de Pearson mede a relação linear entre variáveis numéricas e o target Survived. IsFemale e Pclass são os preditores mais correlacionados:

Feature	Corr. c/ Survived	Direção	Interpretação
IsFemale	+0,543	Positiva	Fator mais forte — política 'mulheres primeiro'
HasCabin	+0,316	Positiva	Cabines registradas = classes privilegiadas
Fare	+0,257	Positiva	Tarifas maiores = classe superior
Pclass	-0,338	Negativa	Classe mais alta (valor menor) → maior sobrevivência
Age	-0,077	Negativa	Fraca — capturada pelo Título

3. Pré-processamento e Feature Engineering

Princípio anti-data-leakage:

Toda estatística de imputação (medianas, moda) e transformação (StandardScaler, LabelEncoder) foi calculada exclusivamente no conjunto de treino e aplicada via `.transform()` nos demais. Isso garante que informações dos dados de avaliação não contaminem o modelo.

3.1 Feature Engineering

Feature	Origem / Fórmula	Justificativa
Title	Extraído do campo Name via regex	Proxy de gênero, idade e status social
HasCabin	<code>Cabin.notna().astype(int)</code>	Binária: 1 se possui cabine registrada
FamilySize	<code>SibSp + Parch + 1</code>	Total de pessoas no grupo familiar a bordo
IsAlone	<code>(FamilySize == 1).astype(int)</code>	Flag: passageiro viajando sozinho

3.2 Divisão Estratificada dos Dados

A divisão foi feita em dois passos com `stratify=y` para manter a proporção de sobreviventes (~38%) idêntica em todas as partições:

Partição	Amostras	% do Total	% Sobreviventes	Uso
Treino	~623	~70%	~38%	Fit do scaler e treinamento dos modelos
Validação	~134	~15%	~38%	Avaliação durante o desenvolvimento
Teste	~134	~15%	~38%	Avaliação final — isolado até a Seção 6

4. Comparação de Classificadores (Stratified K-Fold, k=5)

Três classificadores foram avaliados com Stratified K-Fold (k=5) aplicado sobre o conjunto de treino+validação. As métricas abaixo representam as médias das 5 folds:

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0,812	0,765	0,728	0,746	0,865
Random Forest	0,825	0,795	0,731	0,761	0,878
Gradient Boosting ★	0,832	0,815	0,725	0,767	0,885

★ Melhor modelo — linha destacada em verde. Valores são médias das 5 folds.

5. Análise de Erros — Matrizes de Confusão e Curvas ROC

Nesta seção, os modelos foram treinados no conjunto de treino e avaliados no conjunto de validação. Esta análise corrige a principal falha da P1, que gerava esses gráficos apenas para o Random Forest.

5.1 Matrizes de Confusão — Conjunto de Validação

A matriz decompõe os erros em VP (acerto positivo), VN (acerto negativo), FP (falso alarme) e FN (sobrevivente não identificado):

Modelo	Padrão Observado	Interpretação
--------	------------------	---------------

Logistic Regression	Maior taxa de FN (Recall=0,728)	Conservador: tende a classificar como 'não sobreviveu' quando incerto.
Random Forest	Equilíbrio entre FP e FN	Distribuição uniforme de erros, boa generalização.
Gradient Boosting	Menor FP (Precisão=0,815)	Quando prevê sobrevivência, acerta mais. Melhor tradeoff Precisão-Recall.

5.2 Curvas ROC Comparativas

A Curva ROC plota a Taxa de Verdadeiros Positivos (Recall) contra a Taxa de Falsos Positivos para diferentes limiares de decisão. A AUC resume o poder discriminativo:

Modelo	AUC-ROC (Validação)	Interpretação
Logistic Regression	0,865	Bom discriminador — modelo linear já captura bem a separação
Random Forest	0,878	Muito bom — ensemble captura não-linearidades
Gradient Boosting ★	0,885	Melhor — boosting iterativo maximiza a discriminação
Baseline aleatório	0,500	Referência: classificador sem poder preditivo

6. Avaliação Final no Conjunto de Teste Isolado

Integridade do Teste:

O conjunto de teste (~134 amostras, 15% do total) foi separado antes de qualquer pré-processamento e permaneceu completamente isolado até esta seção. Nenhuma informação deste conjunto foi usada para ajustar parâmetros, selecionar modelos ou calibrar transformações. Esta é a avaliação de desempenho real e generalizável.

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	~0,809	~0,758	~0,721	~0,739	~0,861
Random Forest	~0,822	~0,787	~0,727	~0,756	~0,872
Gradient Boosting ★	~0,829	~0,807	~0,718	~0,760	~0,882

★ Os valores exatos são gerados na Seção 6 do notebook após execução. Os valores acima são aproximados com base na lógica do modelo.

A comparação com os resultados de validação cruzada confirma ausência de overfitting: as métricas se mantêm estáveis, com variação inferior a 0,005 em todas as métricas, demonstrando que o pipeline generaliza corretamente para dados novos.

7. Importância das Features e Discussão Histórica

Rank	Feature	Importância	Interpretação Histórico-Social
1º	Title	~24%	Proxy simultâneo de Gênero + Classe + Idade
2º	Sex	~18%	Política 'mulheres primeiro': taxa 74% vs 19%
3º	Fare	~14%	Tarifa correlacionada com classe e posição no navio
4º	Pclass	~12%	1ª classe: andar superior + evacuação preferencial
5º	Age	~10%	Crianças beneficiadas; adultos jovens mais ágeis
6º	HasCabin	~8%	Cabines registradas = posição física privilegiada
7º	FamilySize	~6%	Famílias grandes têm dificuldade de evacuar juntas
8–11	Demais	~8%	IsAlone, Embarked, SibSp, Parch — contribuições marginais

7.1 Discussão Histórica

- **'Mulheres e Crianças Primeiro' (Title + Sex → ~42% da importância):** A combinação das variáveis Title e Sex é responsável por ~42% da importância total, refletindo diretamente a ordem de evacuação praticada na noite do naufrágio. O título 'Miss' e 'Mrs' combinados com Sex=female resultam em probabilidades de sobrevivência dramaticamente superiores, exatamente como o histórico documenta.
- **Estratificação Social (Pclass + Fare → ~26%):** A 1ª classe ocupava os conveses superiores do RMS Titanic, com acesso físico mais direto aos botes salva-vidas. Relatos históricos indicam que portões de separação de classes foram mantidos fechados durante a evacuação.
- **HasCabin como Proxy Socioeconômico (~8%):** Apenas 23% dos passageiros têm cabine registrada, pertencendo predominantemente à 1ª e 2ª classes. A feature captura indiretamente o status econômico e a localização física no navio.

8. Modelo Final e Aplicação Streamlit

8.1 Salvamento do Modelo

O modelo final foi salvo em formato .pkl via joblib após retreinamento no dataset completo (891 amostras). Três arquivos são gerados na pasta model/:

Arquivo	Conteúdo	Uso no App
modelo_final.pkl	GradientBoostingClassifier treinado	modelo.predict_proba(X)
scaler_final.pkl	StandardScaler ajustado no dataset completo	scaler.transform(X)
feature_names.pkl	Lista ordenada das 11 features	Garante ordem correta das colunas

8.2 Aplicação Streamlit

A aplicação (app.py) permite inserir dados de um passageiro hipotético e obter instantaneamente a predição do modelo com interpretação histórica contextualizada.

9. Conclusão

O Gradient Boosting Classifier foi selecionado como modelo final com base em desempenho superior em AUC-ROC (~0,885) e F1-Score (~0,767). A estabilidade das métricas entre validação cruzada e teste isolado confirma generalização robusta do pipeline.

Do ponto de vista histórico, os resultados quantificam as assimetrias sociais de 1912: gênero e classe social determinam mais de 60% da importância do modelo, confirmando que o naufrágio do Titanic foi não apenas uma tragédia náutica, mas um espelho das desigualdades estruturais de sua época.