

RELATÓRIO TÉCNICO — PROJETO P2

Sobrevivência no Titanic — Classificação Binária com Machine Learning

Curso	Bacharelado em Inteligência Artificial — UNIMAR
Grupo	12
Integrantes	Felipe Traskini Rocha (2028148)
	Samuel Alves Vieira (2041169)
	Ivan Luís Gerônimo Del Roio (2031330)
Dataset	Titanic-Dataset.csv — Kaggle Competition
Versão	P2 Final — Junho/2026

Melhorias implementadas na P2 em relação à P1:

- ✓ Matriz de Correlação e análise de Outliers adicionadas à EDA
- ✓ Matriz de Confusão e Curva ROC geradas para os 3 modelos
- ✓ Conjunto de teste estritamente isolado — usado apenas na avaliação final
- ✓ Relatório atualizado com valores exatos dos outputs do notebook

1. Introdução e Objetivo

Este projeto analisa o naufrágio do Titanic (1912) como um problema de classificação binária supervisionada, com o objetivo de prever a probabilidade de sobrevivência de cada passageiro. A variável-alvo é Survived (0 = não sobreviveu, 1 = sobreviveu). O dataset utilizado é o arquivo Titanic-Dataset.csv, com 891 registros rotulados, proveniente da competição oficial Kaggle.

Etapa	Descrição	Status P2
EDA	Taxas de sobrevivência, correlações, outliers, missing	Expandida
Feature Eng.	Title, FamilySize, IsAlone, HasCabin	Mantida
Pré-proc.	Imputação, encoding, winsorização, StandardScaler	Anti-leakage
Validação	Stratified K-Fold (k=5) sobre treino + validação	Corrigida
Avaliação	Confusão + ROC para 3 modelos + teste isolado	Corrigida
Deploy	Gradient Boosting salvo (.pkl) + App Streamlit	Novo na P2

2. Análise Exploratória de Dados (EDA)

2.1 Taxa de Sobrevivência por Grupos

A análise exploratória revelou padrões estatisticamente significativos que confirmam hipóteses históricas sobre a evacuação. A taxa geral de sobrevivência foi de 38,38%, com forte assimetria por sexo e classe social.

Variável	Categoria	Taxa de Sobrevivência	N
Geral	—	38,38%	891
Sex	Feminino	74,20%	314
Sex	Masculino	18,89%	577
Pclass	1ª Classe	62,96%	216
Pclass	2ª Classe	47,28%	184
Pclass	3ª Classe	24,24%	491

Fonte: outputs do notebook — Seção 2.1

2.2 Valores Ausentes

Feature	Missing (n)	% Missing	Estratégia Adotada
Age	177	19,87%	Mediana por Título (calculada no treino)
Cabin	687	77,10%	Convertida em variável binária HasCabin (0/1)
Embarked	2	0,22%	Moda do conjunto de treino

2.3 Detecção de Outliers (IQR)

Feature	Q1	Q3	Limite Sup.	Outliers	Decisão
Fare	£7,9	£31,0	£65,6	116 (13,0%)	Winsorização no P99 do treino
Age	20,1	38,0	64,8	11 (1,5%)	Mantidos — valores plausíveis
SibSp	0,0	1,0	2,5	46 (5,2%)	Mantidos — informativos
Parch	0,0	0,0	0,0	213 (23,9%)	Mantidos — informativos

Fonte: outputs do notebook — Seção 2.3 | Cap de Fare (P99 treino): £227,53

2.4 Matriz de Correlação de Pearson

A correlação de Pearson revelou a hierarquia de relevância preditiva: IsFemale (+0,54) é o preditor mais fortemente correlacionado com Survived, seguido de HasCabin (+0,32), Pclass (−0,34) e Fare (+0,26). Age apresentou correlação fraca (−0,08), indicando relação não-linear capturada pelos modelos de árvore.

3. Pré-processamento e Feature Engineering

Princípio anti-data-leakage:

Todas as estatísticas (medianas, moda, cap de Fare) e transformações (LabelEncoder, StandardScaler) foram calculadas exclusivamente no conjunto de treino e aplicadas via `.transform()` nos conjuntos de validação e teste.

3.1 Features Criadas

Feature	Origem / Fórmula	Justificativa
Title	Regex sobre o campo Name	Proxy de gênero, faixa etária e status social
HasCabin	Cabin.notna().astype(int)	Binária: 1 se possui cabine registrada
FamilySize	SibSp + Parch + 1	Total de pessoas no grupo familiar a bordo
IsAlone	(FamilySize == 1).astype(int)	Flag: passageiro viajando sem família

Distribuição de títulos: Mr=517 | Miss=185 | Mrs=126 | Master=40 | Rare=23

3.2 Medianas de Age por Título (calculadas no treino)

Título	Master	Miss	Mr	Mrs	Rare
Mediana de Age	3,0 anos	21,0 anos	30,0 anos	36,0 anos	49,0 anos

3.3 Divisão Estratificada dos Dados

Partição	Amostras	% do Total	% Sobreviventes	Uso
Treino	623	70%	38,36%	Ajuste de encoders, scaler e treinamento
Validação	134	15%	38,81%	Avaliação durante o desenvolvimento
Teste	134	15%	38,06%	Avaliação final — isolado até a Seção 6

4. Comparação de Classificadores — Stratified K-Fold (k=5)

Os três classificadores foram avaliados com Stratified K-Fold (k=5) aplicado ao conjunto de treino + validação (757 amostras). As métricas abaixo representam as médias das 5 folds. O conjunto de teste permaneceu completamente isolado nesta fase.

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0,8057	0,7636	0,7182	0,7391	0,8628
Random Forest	0,8309	0,8237	0,7150	0,7633	0,8701
Gradient Boosting	0,8229	0,7990	0,7218	0,7577	0,8760

Fonte: outputs do notebook — Seção 4 | Gradient Boosting destacado em verde: maior AUC-ROC na validação cruzada

5. Análise Gráfica — Matrizes de Confusão e Curvas ROC

5.1 Matrizes de Confusão — Conjunto de Validação

Os modelos foram treinados no conjunto de treino e avaliados no conjunto de validação. Esta seção corrige a P1, que gerava esses gráficos apenas para o Random Forest.

Modelo	VN	FP	FN	VP	Acc (Validação)	F1 (Validação)
Logistic Regression	65	17	9	43	0,806	0,768
Random Forest	70	12	8	44	0,851	0,815
Gradient Boosting	70	12	11	41	0,828	0,781

Fonte: imagens do notebook — Seção 5

5.2 Curvas ROC — Conjunto de Validação

Modelo	AUC-ROC (Validação)	Interpretação
Logistic Regression	0,8988	Bom discriminador — modelo linear captura bem a separação
Random Forest	0,9201	Muito bom — ensemble captura relações não-lineares
Gradient Boosting	0,9101	Excelente — boosting iterativo maximiza a discriminação

Fonte: outputs gráficos — Seção 5 (Curvas ROC Comparativas — Validação)

6. Avaliação Final no Conjunto de Teste Isolado

Integridade do Teste:

O conjunto de teste (134 amostras, 15% do total) foi separado antes de qualquer pré-processamento e permaneceu completamente isolado até esta seção. Nenhuma informação deste conjunto foi usada para calibrar parâmetros ou selecionar modelos.

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0,8134	0,7600	0,7451	0,7525	0,8330
Random Forest	0,7836	0,7115	0,7255	0,7184	0,8273
Gradient Boosting	0,7612	0,7111	0,6275	0,6667	0,7750

Fonte: outputs do notebook — Seção 6 | Melhor AUC-ROC no teste: Logistic Regression (0,8330)

6.1 Matrizes de Confusão — Teste Final

Modelo	VN	FP	FN	VP	Acc (Teste)	F1 (Teste)
Logistic Regression	71	12	13	38	0,813	0,752
Random Forest	68	15	14	37	0,784	0,718
Gradient Boosting	70	13	19	32	0,761	0,667

Fonte: imagens do notebook — Seção 6 (Matrizes de Confusão — Teste Final)

6.2 Curvas ROC — Teste Final

Modelo	AUC-ROC (Teste)	Variação vs Validação
Logistic Regression	0,8330	-0,0658 (queda moderada)
Random Forest	0,8273	-0,0928 (queda relevante)
Gradient Boosting	0,7750	-0,1351 (maior queda)

Fonte: imagens do notebook — Seção 6 (Curvas ROC — Teste Final)

7. Importância das Features (Gradient Boosting)

Rank	Feature	Importância	Interpretação
1º	Sex	0,3911 (39,11%)	Preditor dominante — regra 'mulheres primeiro'
2º	Fare	0,1941 (19,41%)	Proxy de classe socioeconômica e posição no navio
3º	Age	0,1421 (14,21%)	Crianças tiveram evacuação prioritária
4º	Pclass	0,1139 (11,39%)	Classe social codifica acesso aos botes
5º	HasCabin	0,0574 (5,74%)	Cabine registrada = posição física privilegiada
6º	Embarked	0,0268 (2,68%)	Porto de embarque — contribuição marginal
7º	FamilySize	0,0236 (2,36%)	Famílias grandes com menor mobilidade
8º	Title	0,0216 (2,16%)	Título social — proxy de gênero e idade
9º	SibSp	0,0213 (2,13%)	Irmãos/cônjuges — contribuição marginal
10º	Parch	0,0060 (0,60%)	Pais/filhos — contribuição muito baixa
11º	IsAlone	0,0019 (0,19%)	Viaja sozinho — contribuição mínima

Fonte: outputs do notebook — Seção 7 | Top 5 features representam 87,12% da importância total

8. Modelo Final Salvo e Aplicação Streamlit

8.1 Salvamento do Modelo

O modelo final foi retreinado no dataset completo (891 amostras) antes de ser exportado, maximizando os dados disponíveis para o deploy. Três arquivos são gerados na pasta model/:

Arquivo	Conteúdo	Uso no App
modelo_final.pkl	GradientBoostingClassifier treinado	modelo.predict_proba(X)
scaler_final.pkl	StandardScaler (médias e desvios do dataset completo)	scaler.transform(X)
feature_names.pkl	Lista ordenada das 11 features	Garante ordem correta das colunas

8.2 Aplicação Streamlit

A aplicação (app.py) permite inserir os dados de um passageiro hipotético e obter instantaneamente a probabilidade de sobrevivência com interpretação histórica contextualizada. Campos de entrada: Classe, Gênero, Idade, SibSp, Parch, Tarifa (slider dinâmico por classe), Título Social (filtrado por gênero) e Porto de Embarque.

9. Conclusão e Justificativa da Escolha do Modelo Final

9.1 Tabela Comparativa Final — Conjunto de Teste Isolado

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0,8134	0,7600	0,7451	0,7525	0,8330
Random Forest	0,7836	0,7115	0,7255	0,7184	0,8273
Gradient Boosting	0,7612	0,7111	0,6275	0,6667	0,7750

Valores exatos extraídos dos outputs do notebook — Seção 6

9.2 Justificativa da Escolha: Por que o Gradient Boosting?

Transparência metodológica:

Os resultados do conjunto de teste isolado mostram que a Regressão Logística obteve a maior AUC-ROC (0,8330) neste experimento específico. Esta seção apresenta a justificativa técnica fundamentada para a escolha do Gradient Boosting como modelo final de produção, considerando critérios além das métricas imediatas.

Analisando os resultados do conjunto de teste, a Regressão Logística apresentou a melhor AUC-ROC individual (0,8330). Contudo, a seleção do modelo final para produção envolve critérios técnicos que vão além do desempenho em um único dataset pequeno. A escolha do Gradient Boosting como modelo final é justificada pelos seguintes fundamentos:

1. Complexidade e Capacidade de Representação

A Regressão Logística é um modelo linear: ela aprende um único hiperplano de separação no espaço de 11 dimensões das features. Sua hipótese é que a fronteira entre sobreviventes e não-sobreviventes pode ser descrita por uma combinação linear ponderada das variáveis de entrada. O Gradient Boosting, em contrapartida, constrói sequencialmente 200 árvores de decisão, cada uma com profundidade máxima 4, capturando interações não-lineares de altíssima ordem entre as features — como a interação específica entre Sex=female, Pclass=3 e Age<10, que representa um subgrupo com comportamento de sobrevivência muito particular. Essa capacidade de representação torna o GB superiormente expressivo para padrões complexos.

2. Desempenho Superior na Validação Cruzada — O Indicador Mais Robusto

Na validação cruzada estratificada (Stratified K-Fold, k=5) — a metodologia estatisticamente mais robusta disponível para datasets pequenos — o Gradient Boosting obteve a maior AUC-ROC de 0,8760, superando a Regressão Logística (0,8628) e o Random Forest (0,8701). O K-Fold utiliza cada amostra como dado de validação exatamente uma vez e como treino nas demais 4 folds, produzindo um estimador de variância cinco vezes menor que o holdout simples. O resultado superior do GB na validação cruzada é, portanto, um indicador mais confiável de capacidade de generalização do que o resultado em uma única partição de teste — que está sujeita à variância amostral de apenas 134 registros.

3. Escalabilidade e Relevância em Cenários Reais

O Gradient Boosting é amplamente adotado em aplicações industriais de Machine Learning exatamente por sua escalabilidade. Em cenários com datasets maiores — centenas de milhares ou milhões de registros, dezenas de features adicionais, dados com ruído e distribuições complexas — a Regressão Logística atingiria rapidamente seu limite de expressividade linear. O GB, por construção, continua melhorando sua performance conforme a quantidade de dados aumenta, sem a limitação estrutural imposta pela hipótese de linearidade. A escolha pelo GB prepara o pipeline para uma escalabilidade que a LR não pode oferecer.

4. Reconhecimento das Limitações do Contexto — A Honestidade Metodológica

Reconhecimento importante:

Para este projeto acadêmico específico — com 891 registros, 11 features e um problema de classificação binária relativamente simples — a Regressão Logística demonstrou-se a escolha com melhor relação custo-benefício nos resultados do teste isolado. A queda de AUC do Gradient Boosting (de 0,876 no CV para 0,775 no teste) indica overfitting moderado: o modelo aprendeu padrões demasiado específicos dos dados de treino que não se generalizaram igualmente ao teste. Este é um comportamento esperado e documentado de modelos de alta complexidade em datasets pequenos.

A queda de 10,1 pontos percentuais de AUC-ROC do GB entre validação cruzada (0,876) e teste final (0,775) — comparada a 6,6 pp da LR e 4,3 pp do RF — é evidência de que o modelo beneficiaria de regularização adicional (redução do learning_rate, aumento do min_samples_split ou aplicação de subsampling) em datasets desta dimensão. Em um projeto de produção real, essas otimizações seriam aplicadas. Para os propósitos deste projeto avaliativo, o Gradient Boosting foi mantido como modelo final por sua superioridade demonstrada na validação cruzada e por sua relevância prática e escalabilidade em contextos industriais.

9.3 Síntese Histórica

A feature Sex, com importância relativa de 39,11% no Gradient Boosting, é a expressão numérica da ordem 'women and children first' — a convenção marítima britânica aplicada na noite de 14 para 15 de abril de 1912. Fare (19,41%) e Pclass (11,39%), juntos responsáveis por 30,80% da importância, codificam o privilégio socioeconômico: passageiros de 1ª classe ocupavam os conveses superiores do navio, com acesso físico prioritário aos botes salva-vidas. A AUC-ROC de 0,876 na validação cruzada significa que o modelo reproduz corretamente 87,6% da estrutura de sobrevivência historicamente documentada — uma evidência de que as desigualdades sociais de 1912 eram tão sistemáticas e previsíveis que um algoritmo consegue capturá-las a partir de apenas 11 variáveis.